

# Beschreibende Statistik mit einem Merkmal

## Häufigkeiten

### Funktion

Merkmalsausprägung:  $a_k$

absolute Häufigkeit:  $h_k$

kumulative absolute Häufigkeit:  $H_k = h_1 + \dots + h_k$

relative Häufigkeit:  $f_k = \frac{h_k}{n}$

kumulative relative Häufigkeit:  $F_k = f_1 + \dots + f_k$


### z.B. Ganze Noten 1-6 ( $n=10$ )

1	2	3	4	5	6
0	1	2	4	2	1

0	1	3	7	9	10
0	$\frac{1}{10}$	$\frac{2}{10}$	$\frac{4}{10}$	$\frac{2}{10}$	$\frac{1}{10}$


0	$\frac{1}{10}$	$\frac{3}{10}$	$\frac{7}{10}$	$\frac{9}{10}$	1
0	$\frac{1}{10}$	$\frac{3}{10}$	$\frac{7}{10}$	$\frac{9}{10}$	1

## Relative Häufigkeitsfunktion (PMF)



$$\text{relative Häufigkeit } x = 3.5 = 0$$

## Kumulative Verteilungsfunktion (CDF)



$$\text{Summe relativen Häufigkeiten } x \leq 3.5 = 0.3$$

z.B.  $n=10$  mit Hilfe von CDF

$$\text{Anzahl Daten genau (=) Wert 4: } 10 \cdot 0.4 = 4$$

$$\text{Anzahl Daten max. (\leq) Wert 4: } 10 \cdot 0.7 = 7$$

$$\text{Anzahl Daten mind. (>) Wert 4: } 10 \cdot 0.7 = 7$$

## Klassen

Zusammenfassung von mehreren Merkmalsausprägungen

### Funktion

Klassenbereich:  $a_k$  bis  $a_{k+1}$

Klassenbreite:  $b_k = a_{k+1} - a_k$

absolute Häufigkeit:  $h_k$

relative Häufigkeit:  $p_k = \frac{h_k}{n}$

relative Häufigkeitsdichte:  $f_k = \frac{p_k}{b_k}$

kumulative relative Häufigkeit:  $F_k = f_1 + \dots + f_k$


### z.B. Ganze Noten 1-6

[1,4[	[4,6]
3	2
$\frac{3}{10}$	$\frac{7}{10}$
$0.3 = 0.1$	$0.7 = 0.35$
$\frac{3}{10}$	1

## Lineare Interpolation / Quantile bei klassierten Daten


Bestimmung  $\tilde{x}_q$  /  $F(x)$  aus klassierter CDF

$$F(x) - F(a) = \frac{F(b) - F(a)}{b-a} \cdot (x-a)$$



### z.B. Klasse

$p_k$	0.2	0.4	0.4
$F_k$	0.2	0.6	1



$x$  für  $F(x) = \tilde{x}_{0.35}$

$$a = 170, b = 180, F(a) = 0.2, F(b) = 0.6$$

$$\frac{0.35 - 0.2}{0.15} = \frac{0.6 - 0.2}{180 - 170} \cdot (\tilde{x}_{0.35} - 170)$$

$$0.15 = 0.04 \cdot \tilde{x}_{0.35} - 6.8$$

$$6.95 = 0.04 \cdot \tilde{x}_{0.35}$$

$$173.75 = \tilde{x}_{0.35}$$

$x$  für  $F(x) = \tilde{x}_{0.1}$

$$a = 160, b = 170, F(a) = 0, F(b) = 0.2$$

$$0.1 - 0 = \frac{0.2 - 0}{170 - 160} \cdot (\tilde{x}_{0.1} - 160) \rightarrow 0.1 = 0.02 \tilde{x}_{0.1} - 3.2$$

$$165 = \tilde{x}_{0.1}$$

$F(x)$  für  $x = 173.75$

$$a = 170, b = 180, F(a) = 0.2, F(b) = 0.6$$

$$F(173.75) - 0.2 = \frac{0.6 - 0.2}{180 - 170} \cdot (173.75 - 170)$$

$$F(173.75) = 0.15 + 0.2 = 0.35$$

## Quantile bei nicht klassierten Daten

Gegeben: **Aufsteigend sortierte** Datenwerte  $x_1 \leq \dots \leq x_n$ , Anteil  $0 < q < 1$

$$\tilde{x}_q = \begin{cases} \frac{1}{2} \cdot (x_{q \cdot n} + x_{q \cdot n+1}) & \text{wenn } q \cdot n \text{ ganzzahlig} \\ x_{\lceil q \cdot n \rceil} & \text{wenn } q \cdot n \text{ nicht ganzzahlig} \end{cases}$$

aufrunden auf nächste ganze Zahl

z.B. Körpergrößen Männer ( $n = 10$ ): 164, 166, 174, 174, 174, 178, 182, 182, 188, 198

0.2-Quantil:  $q \cdot n = 0.2 \cdot 10 = 2 \rightarrow \text{ganzzahlig}$


$$\tilde{x}_{0.2} = \frac{1}{2} \cdot (x_2 + x_3) = \frac{1}{2} (166 + 174) = 170$$

Anteil Daten unterhalb: 0.2 / oberhalb: 1 - 0.2 = 0.8

0.55-Quantil:  $q \cdot n = 0.55 \cdot 10 = 5.5 \rightarrow \text{nicht ganzzahlig}$

$$\tilde{x}_{0.55} = x_{\lceil 0.55 \rceil} = x_6 = 178$$

Anteil Daten unterhalb: 0.55 / oberhalb: 1 - 0.55 = 0.45



## Lagemasse

Charakterisiert das Zentrum der Daten,  $n$  Datenwerte  $x_1, \dots, x_n$

Median:  $\tilde{x} = 0.5\text{-Quantil } \tilde{x}_{0.5}$

Arithmetisches Mittel / Mittelwert:  $\bar{x} = \frac{x_1 + \dots + x_n}{n}$

mit relativen Häufigkeiten  $f_1, \dots, f_n$ :  $\bar{x} = (f_1 \cdot x_1) + \dots + (f_n \cdot x_n)$

z.B. Körpergrößen Männer

Median:  $\tilde{x} = 176$

$$\text{Mittelwert: } \bar{x} = \frac{164 + 166 + (3 \cdot 174) + 178 + (2 \cdot 182) + 188 + 198}{10} = \frac{1780}{10} = 178$$

z.B. Ganze Noten 1-6 mit relativen Häufigkeiten

$$\text{Mittelwert: } \bar{x} = (0 \cdot 1) + (0.1 \cdot 2) + (0.2 \cdot 3) + (0.4 \cdot 4) + (0.2 \cdot 5) + (0.1 \cdot 6) = 4$$

Klassen (nur Approximation möglich):

$$\text{Klassenmitten: } [1, 4] \rightarrow 2.5, [4, 6] \rightarrow 5 \quad (6-4=2 \rightarrow 2:2=1 \rightarrow 6-1=5)$$

$$\text{Mittelwert: } \bar{x} = (0.3 \cdot 2.5) + (0.7 \cdot 5) = 4.25$$


**Boxplot** ① Nur für nicht klassierte Daten

**Aufsteigend sortiert**

1. Quartil  $q_1 = 0.25\text{-Quantil } \tilde{x}_{0.25}$

2. Quartil  $q_2 = \text{Median } \tilde{x} = 0.5\text{-Quantil } \tilde{x}_{0.5}$

3. Quartil  $q_3 = 0.75\text{-Quantil } \tilde{x}_{0.75}$




z.B. Körpergrößen Männer

1. Quartil  $q_1 = 174$

Median  $\tilde{x} = 176$

3. Quartil  $q_3 = 182$

$$\text{Interquartilsabstand} = 182 - 174 = 8 \rightarrow 1.5 \cdot 8 = 12$$



## Streuungsmasse

Charakterisiert Datenabweichung vom Zentrum,  $n$  Datenwerte  $x_1, \dots, x_n$

Interquartilsabstand: 3. Quartil - 2. Quartil =  $q_3 - q_2$

$$\text{Varianz (Masseinheit im Quadrat): } \tilde{\sigma}^2 = \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n} = \frac{x_1^2 + \dots + x_n^2}{n} - \bar{x}^2$$

mit relativen Häufigkeiten:  $\tilde{\sigma}^2 = f_1 \cdot (x_1 - \bar{x})^2 + \dots + f_n \cdot (x_n - \bar{x})^2 = (f_1 \cdot x_1^2 + \dots + f_n \cdot x_n^2) - \bar{x}^2$

$$\text{korrigierte: } v = \frac{\tilde{\sigma}^2 \cdot n}{n-1}$$


$$\text{Standardabweichung (Masseinheit identisch): } \tilde{s} = \sqrt{\tilde{\sigma}^2}$$

$$\text{korrigierte: } s = \sqrt{v}$$


Resultat immer positiv oder null

## Form der Datenverteilung


Mittelwert:  $\bar{x}$ , Median:  $\tilde{x}$



$\bar{x} < \tilde{x}$ : asymmetrisch linksschief



$\bar{x} \approx \tilde{x}$ : näherungsweise symmetrisch



$\bar{x} > \tilde{x}$ : asymmetrisch rechtsschief

z.B. Ganze Noten 1-6 mit relativen Häufigkeiten

$$\text{Varianz: } \tilde{\sigma}^2 = (0 \cdot 1)^2 + (0.1 \cdot 2)^2 + (0.2 \cdot 3)^2 + (0.4 \cdot 4)^2 + (0.2 \cdot 5)^2 + (0.1 \cdot 6)^2 = 4^2 = 1.2$$

Klassen (nur Approximation möglich):


$$\text{Klassenmitten: } [1, 4] \rightarrow 2.5, [4, 6] \rightarrow 5 \quad (4-1=3 \rightarrow 3:2=1.5 \rightarrow 4-1.5=2.5), [4, 6] \rightarrow 5$$

$$\text{Varianz: } \tilde{\sigma}^2 = (0.3 \cdot 2.5^2 + 0.7 \cdot 5^2) - 4^2 = 3.375$$

# Beschreibende Statistik mit mehreren Merkmalen

## Streudiagramm

z.B. Zusammenhang Grösse und Gewicht								Summe	Mittelwert
Grösse in cm	186	174	170	174	180	175	182	183	1'424
Gewicht in kg	80	63	60	72	65	68	70	74	552



## Korrelation

Statistischer linearer Zusammenhang zweier Merkmale

Positive Korrelation: meisten Datenpunkte in ① und ③ → Kovarianz positiv

Negative Korrelation: meisten Datenpunkte in ② und ④ → Kovarianz negativ

Keine Korrelation: etwa gleich viele Datenpunkte in ① und ④ → Kovarianz nahe null

z.B. Grösse und Gewicht sind positiv korreliert, gross → gross / klein → klein  
 ↴ wenn negativ korreliert, gross → klein / klein → gross

## Datenränge anstatt Datenwerte

Minderung des Einflusses von Ausreisern

! Bei gleichem Wert geteilter Rang verwenden. z.B. Rang 2 und 3 gleich →  $\frac{2+3}{2} = 2.5$

z.B. Zusammenhang Grösse und Gewicht								Summe	Mittelwert
rg(Grösse)	8	2.5	1	2.5	5	4	6	7	36
rg(Gewicht)	8	2	1	6	3	4	5	7	36

## Kovarianz

Abweichungsmittelwert der Datenwerte zum Datenmittelwert,  $n$  Datenpaare  $(x_1, y_1), \dots, (x_n, y_n)$  mit Mittelwerten  $\bar{x}, \bar{y}$

$$\tilde{v}_{xy} = \frac{(x_1 - \bar{x}) \cdot (y_1 - \bar{y}) + \dots + (x_n - \bar{x}) \cdot (y_n - \bar{y})}{n} = \frac{x_1 \cdot y_1 + \dots + x_n \cdot y_n}{n} - \bar{x} \cdot \bar{y}, \quad \tilde{v}_{xy} = \frac{rg(x_1) \cdot rg(y_1) + \dots + rg(x_n) \cdot rg(y_n)}{n} - \bar{x} \cdot \bar{y}$$

z.B. Zusammenhang Grösse und Gewicht (Datenwerte)

$$\tilde{v}_{xy} = \frac{186 \cdot 80 + 174 \cdot 63 + 170 \cdot 60 + 174 \cdot 72 + 180 \cdot 65 + 175 \cdot 68 + 182 \cdot 70 + 183 \cdot 74}{8} - 178 \cdot 69 = 24.5$$

z.B. Zusammenhang Grösse und Gewicht (Datenränge)

$$\tilde{v}_{xy} = \frac{8 \cdot 8 + 2 \cdot 5 \cdot 2 + 1 \cdot 1 + 2 \cdot 5 \cdot 6 + 5 \cdot 3 + 4 \cdot 4 + 6 \cdot 5 + 7 \cdot 7}{8} - 4.5 \cdot 4.5 = 4.125$$

## Korrelationskoeffizient

① Pearson: Datenwerte / Spearman: Datenränge

Standardabweichungen  $\tilde{s}_x, \tilde{s}_y$

$$r_{xy} = \frac{\tilde{v}_{xy}}{\tilde{s}_x \cdot \tilde{s}_y} \quad \text{(keine Maßeinheit)} \quad \left. \begin{array}{l} \text{Resultat} \\ \text{von -1 bis 1} \end{array} \right.$$

Korrelation Faustregel:

- 1 bis -0.75 / 0.75 bis 1 : stark negativ/positiv
- 0.75 bis -0.5 / 0.5 bis 0.75 : moderat negativ/positiv
- 0.5 bis -0.25 / 0.25 bis 0.5 : schwach negativ/positiv
- 0.25 bis 0.25 : keine

z.B. Zusammenhang Grösse und Gewicht (Pearson)

$$\tilde{s}_x = \sqrt{26.75}, \tilde{s}_y = \sqrt{36.25}, \tilde{v}_{xy} = 24.5$$

$$r_{xy} \approx \frac{24.5}{\sqrt{5.17} \cdot \sqrt{6.02}} \approx 0.79 \rightarrow \text{stark positive Korrelation}$$

z.B. Zusammenhang Grösse und Gewicht (Spearman)

$$\tilde{s}_x = \sqrt{5.18}, \tilde{s}_y = \sqrt{5.25}, \tilde{v}_{xy} = 4.125$$

$$r_{xy} \approx \frac{4.125}{\sqrt{2.27} \cdot \sqrt{2.29}} \approx 0.79 \rightarrow \text{stark positive Korrelation}$$

## Hilfstabellen Berechnung

Pearson:

i	...	Summe	Mittelwert
$x_i$	...		
$y_i$	...		
$x_i^2$	...		
$y_i^2$	...		
$x_i \cdot y_i$	...		

Spearman:

i	...	Summe	Mittelwert
$x_i$	...		
$y_i$	...		
$rg(x_i)$	...		
$rg(y_i)$	...		
$rg(x_i)^2$	...		
$rg(y_i)^2$	...		
$rg(x_i) \cdot rg(y_i)$	...		

# Kombinatorik

**Produktregel:** Zählen geht über  $k$  Stufen

Insgesamt:  $n_1 \cdot \dots \cdot n_k$  Möglichkeiten

**Summenregel:** Beim Zählen treten  $j$  verschiedene Fälle auf

Insgesamt:  $m_1 + \dots + m_j$  Möglichkeiten

**Komplementregel:** Beim Zählen gibt es  $n$  Möglichkeiten

$p$  Möglichkeiten mit der Eigenschaft ( $p = n - q$ )

$q$  übrigen Möglichkeiten ohne die Eigenschaft

## Beispiele

4-stellige PIN-Codes aus Ziffern 0 bis 9, Anzahl Kombinationen

mit lauter geraden Ziffern:

$$\hookrightarrow 5^4 = 625$$

mit lauter verschiedenen ungeraden Ziffern:

$$\hookrightarrow 5 \cdot 4 \cdot 3 \cdot 2 = 120$$

mit entweder lauter gleichen oder verschiedenen Ziffern:

$$\hookrightarrow 1. Fall \text{ alle gleich: } 10 \cdot 1 \cdot 1 \cdot 1 = 10$$

$$\hookrightarrow 2. Fall \text{ alle verschieden: } 10 \cdot 9 \cdot 8 \cdot 7 = 5040$$

$$10 + 5040 = 5050$$

mit mind. 2 gleichen Ziffern:

$$\hookrightarrow n \text{ alle Möglichkeiten: } 10^4 = 10000$$

$$q \text{ alle Ziffern verschieden: } 10 \cdot 9 \cdot 8 \cdot 7 = 5040$$

$$10000 - 5040 = 4960$$

mit max. 3 gleichen Ziffern:

$$\hookrightarrow n \text{ alle Möglichkeiten: } 10^4 = 10000$$

$$q \text{ alle Ziffern gleich: } 10 \cdot 1 \cdot 1 \cdot 1 = 10$$

$$10000 - 10 = 9990$$

mit mind. je einer geraden und ungeraden Ziffer:

$$\hookrightarrow n \text{ alle Möglichkeiten: } 10^4 = 10000$$

$$q \text{ alle gerade/ungerade: } 1. Fall \text{ alle gerade: } 5^4 = 625$$

$$2. Fall \text{ alle ungerade: } 5^4 = 625$$

$$625 + 625 = 1250 \rightarrow 10000 - 1250 = 8750$$

mit genau einer Ziffer 9:  $(4) \cdot 1 \cdot 9^3 = 2316$

## Typ 1: mit Reihenfolge mit Wiederholung

Möglichkeiten zur Auswahl von  $k$  aus  $n$  Objekten:

$$n \cdot n \cdot \dots \cdot n = n^k$$

z.B. Tupel  $(X, Y, Z)$  mit  $X, Y, Z$  je A, B, C, D, E

$$5 \cdot 5 \cdot 5 = 5^3 = 125$$

## Typ 2: mit Reihenfolge ohne Wiederholung

Möglichkeiten zur Auswahl von  $k$  aus  $n$  Objekten:

$$n \cdot (n-1) \cdot \dots \cdot (n-k+1) = \frac{n!}{(n-k)!} \quad ! 0! = 1, PRB \rightarrow !$$

z.B. Tupel  $(X, Y, Z)$  mit  $X, Y, Z$  je verschiedenen A, B, C, D, E

$$5 \cdot 4 \cdot 3 = \frac{5!}{(5-3)!} = 60$$

z.B. Wettbewerb mit 10 Personen, eine davon ist Alice

Möglichkeiten zur Belegung der ersten 3 Plätze:

$$\hookrightarrow 10 \cdot 9 \cdot 8 = \frac{10!}{(10-3)!} = 720$$

Möglichkeiten für Podest mit Alice:

$$\left. \begin{array}{l} 1. Fall \quad 1. Platz: 1 \cdot 9 \cdot 8 = 1 \cdot \frac{9!}{(9-2)!} = 72 \\ 2. Fall \quad 2. Platz: 9 \cdot 1 \cdot 8 = 1 \cdot \frac{9!}{(9-2)!} = 72 \\ 3. Fall \quad 3. Platz: 9 \cdot 8 \cdot 1 = 1 \cdot \frac{9!}{(9-2)!} = 72 \end{array} \right\} 72 + 72 + 72 = 216$$

z.B. Kurs mit 20 Personen, 8 Frauen und 12 Männer

Möglichkeiten Einerreihe zu bilden:

$$\hookrightarrow \frac{20!}{(20-20)!} = 20! = 2 \cdot 43 \cdot 10^{18}$$

Möglichkeiten Einerreihe zu bilden mit Frauen vorne:

$$\hookrightarrow \frac{8!}{(8-8)!} \cdot \frac{12!}{(12-12)!} = 8! \cdot 12! = 1 \cdot 93 \cdot 10^{13}$$

## Beispiel Kombination Typ 1, 2 und 3

Anzahl Wörter der Länge 5 mit 2 Vokalen und 3 verschiedenen Konstanten:

1. 2 von 5 Stellen an denen Vokale stehen:

$$\hookrightarrow \text{Typ 3: } \binom{5}{2} = 10$$

2. Vokale an in 1. ermittelten Stellen:

$$\hookrightarrow \text{Typ 1: } 2^2 = 4$$

3. Verschiedene Konstanten an in 1. nicht ermittelten Stellen:

$$\hookrightarrow \text{Typ 2: } 4 \cdot 3 \cdot 2 = \frac{4!}{1!} = 24$$

$$\rightarrow \text{Total: } 10 \cdot 4 \cdot 24 = 960$$

## Typ 3: ohne Reihenfolge ohne Wiederholung

Möglichkeiten zur Auswahl von  $k$  aus  $n$  Objekten:

$$\frac{n \cdot (n-1) \cdot \dots \cdot (n-k+1)}{k \cdot (k-1) \cdot \dots \cdot 2 \cdot 1} = \frac{n!}{k! \cdot (n-k)!} = \binom{n}{k} \quad ! PRB \rightarrow nCr$$

z.B. Kurs mit 20 Personen, 8 Frauen und 12 Männer, Bildung einer 4er Gruppe

! Ohne Wiederholung: Anzahl Personen gegeben (Person A in nur 1er Gruppe)

Anzahl möglicher Gruppen insgesamt:

$$\hookrightarrow \binom{20}{4} = 4845$$

Anzahl Gruppen mit nur Männern oder nur Frauen:

$$\left. \begin{array}{l} 1. Fall \text{ nur Männer: } \binom{12}{4} = 495 \\ 2. Fall \text{ nur Frauen: } \binom{8}{4} = 70 \end{array} \right\} 495 + 70 = 565$$

Anzahl Gruppen mit je 2 Männern und 2 Frauen:

$$\hookrightarrow \binom{12}{2} \cdot \binom{8}{2} = 1848$$

Anzahl Gruppen mit mind. 1 Mann und Frau:

$$\left. \begin{array}{l} 1. Fall \text{ 2 Männer und 2 Frauen: } 1848 \\ 2. Fall \text{ 3 Männer und 1 Frau: } \binom{12}{3} \cdot \binom{8}{1} = 1760 \\ 3. Fall \text{ 1 Mann und 3 Frauen: } \binom{12}{1} \cdot \binom{8}{3} = 672 \end{array} \right\} 1848 + 1760 + 672 = 4280$$

## Typ 4: ohne Reihenfolge mit Wiederholung

Möglichkeiten zur Auswahl von  $k$  aus  $n$  Objekten:

$$\frac{(k+n-1)!}{k! \cdot (n-1)!} = \binom{k+n-1}{k} \quad ! PRB \rightarrow nCr$$

z.B. Ausreichend viele Sugus mit und ohne Zucker in 4 Geschmacksrichtungen (8 Sorten)

! Mit Wiederholung: Anzahl Sugus nicht gegeben (Sorte mehrfach ziehbar)

Anzahl Kombinationen wenn 6 Sugus gezogen werden:

$$\hookrightarrow \binom{6+8-1}{6} = 1716$$

Anzahl Kombinationen wenn je 3 Sugus mit und ohne Zucker gezogen werden:

$$\hookrightarrow \binom{3+4-1}{3} \cdot \binom{3+4-1}{3} = 400$$

Anzahl Kombinationen wenn 5 Sugus ohne Erdbeer gezogen werden und alle entweder mit oder ohne Zucker sind:

$$\left. \begin{array}{l} 1. Fall \text{ mit Zucker: } \binom{5+3-1}{5} = 21 \\ 2. Fall \text{ ohne Zucker: } \binom{5+3-1}{5} = 21 \end{array} \right\} 21 + 21 = 42$$

Anzahl Kombinationen wenn 5 Sugus davon mind. 1 Erdbeer gezogen werden:

$$\left. \begin{array}{l} n \text{ alle Kombinationen: } \binom{5+8-1}{5} = 792 \\ q \text{ ohne Erdbeer: } \binom{5+6-1}{5} = 252 \end{array} \right\} 792 - 252 = 540$$

# Elementare Wahrscheinlichkeitsrechnung

## Zufallsexperiment

Vorgang mit mehreren möglichen Ausgängen und einem ungewissen eintretenden Ausgang

## Ergebnisse

Ergebnisse: Mögliche Ausgänge eines Zufallsexperiments  
Bezeichnung mit  $w_1, w_2, \dots$

Ergebnisraum: Menge aller Ergebnisse  
Bezeichnung mit  $\Omega = \{w_1, w_2, \dots\}$

## Ereignisse

Ereignisse: Teilmengen des Ergebnisraums  $\Omega$   
Bezeichnung mit  $A \subseteq \Omega, B \subseteq \Omega, C \subseteq \Omega, \dots$

Elementarereignis: Ereignis mit genau einem Ergebnis

Zusammengesetztes Ereignis: Ereignis mit mehr als einem Ergebnis

Unmögliches Ereignis: Leere Menge  $\{\}$ , tritt nie ein

Sicheres Ereignis: Ganze Ergebnismenge  $\Omega$ , tritt immer ein

## Beispiel

Zufallsexperiment: 2-Mal gleicher Würfel mit Augenzahlen 1,2,3 werfen mit Reihenfolge

Ergebnisse: Augenzahlpaare  $w_1 = (1,1), w_2 = (1,2), \dots, w_9 = (3,3)$

Ergebnisraum:  $\Omega = \{w_1, w_2, \dots, w_9\} = \{(1,1), (1,2), \dots, (3,3)\}$

Ereignisse: A = Nur ungerade Augenzahlen =  $\{(1,1), (1,3), (3,1), (3,3)\}, P(A) = \frac{4}{9}$

↪ Zusammengesetztes Ereignis

B = Nur gerade Augenzahlen =  $\{(2,2)\}, P(B) = \frac{1}{9}$

↪ Elementarereignis

C = Augenzahlprodukt 5 =  $\{\}$ ,  $P(C) = 0$

↪ Unmögliches Ereignis

D = Augenzahlunterschied  $\leq 2 = \Omega, P(D) = 1$

↪ Sicheres Ereignis, Zusammengesetztes Ereignis

## Wahrscheinlichkeit/-mass

Wahrscheinlichkeit von A: Zahl  $P(A)$

Wahrscheinlichkeitsmass auf  $\Omega$ : Funktion  $P$

Eigenschaften: •  $0 \leq P(A) \leq 1$  für alle A

•  $P(\{\}) = 0$  und  $P(\Omega) = 1$

•  $P(A \cup B \cup C \cup \dots) = P(A) + P(B) + P(C) + \dots$  für alle paarweise disjunkt  $A, B, C, \dots$  mit  $A \cap B = \{\}, A \cap C = \{\}, B \cap C = \{\}, \dots$  ↪

•  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

•  $P(\bar{A}) = P(\Omega \setminus A) = 1 - P(A)$

z.B.  $P(\bar{C}) = 0.7, A \cap C = \{\}, P(A \cup C) = 0.9, P(A \cap B) = 0.3, P(A \cup B) = 0.8$

$$P(C) = 1 - P(\bar{C}) = 1 - 0.7 = 0.3$$

$$P(A) = P(A \cup C) - P(C) + P(A \cap C) = 0.9 - 0.3 + 0 = 0.6$$

$$P(B) = P(A \cup B) - P(A) + P(A \cap B) = 0.8 - 0.6 + 0.3 = 0.5$$

## Laplace-Zufallsexperiment

Alle elementaren Ereignisse haben dieselbe Wahrscheinlichkeit

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{Anzahl für } A \text{ günstige Ergebnisse}}{\text{Anzahl insgesamt mögliche Ergebnisse}}$$

z.B. 10 Kugeln von 1-10 nummeriert, 4 Kugeln ohne zurücklegen nacheinander ziehen

↪  $|\Omega| = 10 \cdot 9 \cdot 8 \cdot 7 = 5'040$  (Typ 2) mit Reihenfolge

Alle gezogene Kugeln gerade Nummer:

$$\hookrightarrow |A| = 5 \cdot 4 \cdot 3 \cdot 2 = 120, P(A) = \frac{120}{5'040} \approx 0.0238$$

Erste beiden Kugeln gerade und letzten beiden ungerade Nummern:

$$\hookrightarrow |B| = 5 \cdot 4 \cdot 5 \cdot 4 = 400, P(B) = \frac{400}{5'040} \approx 0.0794$$

Genau eine Kugel gerade Nummer hat:

$$\hookrightarrow |C| = \binom{4}{1} \cdot 5 \cdot 5 \cdot 4 \cdot 3, P(C) = \frac{120}{5'040} \approx 0.2381$$

Fälle gerade ungerade

Mind. eine Kugel ungerade Nummer hat:

$$\hookrightarrow |\bar{D}| = |\Omega| = 120 \rightarrow P(\bar{D}) = P(A) \approx 0.0238$$


$$P(D) = 1 - P(\bar{D}) \approx 0.9762$$

## Wahrscheinlichkeitsverteilung Dichtefunktion PDF

Kein Platz mehr bei Wahrscheinlichkeitsverteilung

$$f_X(t) = \begin{cases} (10 - 2t)/25 & \text{falls } 0 \leq t \leq 5 \\ 0 & \text{sonst} \end{cases}$$

(1P) Skizzieren Sie die Dichtefunktion.



(1P) Berechnen Sie die Wahrscheinlichkeit  $P(X \geq 3)$ .  
 $P(X \geq 3) = 4/25 = 0.16$

(4P) Berechnen Sie den Erwartungswert  $E(X)$  sowie die Varianz  $V(X)$ .

$$E(X) = \int_{-\infty}^{\infty} t \cdot f_X(t) dt = \int_0^5 1/25 \cdot (10t - 2t^2) dt = 1/25 \cdot \left[ 5t^2 - \frac{2}{3}t^3 \right]_0^5 = 1/25 \cdot (125 - 250/3) = 5/3 = 1.6 \text{ und}$$

$$E(X^2) = \int_{-\infty}^{\infty} t^2 \cdot f_X(t) dt = \int_0^5 1/25 \cdot (10t^2 - 2t^3) dt = 1/25 \cdot \left[ \frac{10}{3}t^3 - \frac{2}{4}t^4 \right]_0^5 = 1/25 \cdot (10/3 \cdot 125 - 1/2 \cdot 625) = 25/6$$

$$V(X) = 25/6 - (5/3)^2 = 25/18 = 1.38$$

## Bedingte Wahrscheinlichkeit

A tritt ein, wenn B eingetreten:  $P(A|B) = \frac{P(A \cap B)}{P(B)}$

B tritt ein, wenn A eingetreten:  $P(B|A) = \frac{P(B \cap A)}{P(A)}$

Multiplikationssatz:  $P(A \cap B) = P(B \cap A) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$

z.B. In Klasse mit 24-Schüler haben 18 genügende Note in Mathe und 20 genügende Note in Deutsch. 16 Schüler in beiden Fächern genügend.

Angaben in Vierfeldertafel darstellen:

	D	$\bar{D}$	
M	16	2	18
$\bar{M}$	4	2	6
	20	4	24

Gegeben

Wahrscheinlichkeit ein Schüler in beiden Fächern ungenügend:

$$\hookrightarrow P(\bar{M} \cap \bar{D}) = \frac{2}{24} = \frac{1}{12}$$

Wahrscheinlichkeit ein Schüler entweder in Mathe oder Deutsch ungenügend:

$$\hookrightarrow P(\bar{M} \cup \bar{D}) = P(\bar{M}) + P(\bar{D}) = \frac{4}{24} + \frac{2}{24} = \frac{6}{24} = \frac{1}{4}$$

Wahrscheinlichkeit ein Schüler, der in Deutsch genügend ist, es auch in Mathe ist:

$$\hookrightarrow P(M|D) = P(M \cap D) : P(D) = \frac{16}{24} : \frac{20}{24} = \frac{16}{20} = \frac{4}{5}$$

Wahrscheinlichkeit ein Schüler, der in Mathe ungenügend ist, es auch in Deutsch ist:


$$\hookrightarrow P(\bar{D}|\bar{M}) = P(\bar{D} \cap \bar{M}) : P(\bar{M}) = \frac{2}{24} : \frac{6}{24} = \frac{2}{6} = \frac{1}{3}$$

## Satz von Bayes

Gegeben:  $P(A)$ ,  $P(B)$  und  $P(B|A)$  / Gesucht:  $P(A|B)$

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)} \quad \text{! Wechsel der Bedingung}$$

z.B. Kurs mit 40% Frauen davon rauchen 20%, 60% Männer davon rauchen 10%



Zufällig ausgewählte rauchende Person ist ein Mann:  $P(M|R) = \frac{P(M) \cdot P(R|M)}{P(R)} = \frac{0.6 \cdot 0.1}{0.14} \approx 0.429$

Zufällig ausgewählte nichtrauchende Person ist eine Frau:  $P(F|N) = \frac{P(F) \cdot P(N|F)}{P(N)} = \frac{0.4 \cdot 0.8}{0.86} \approx 0.372$


## Ereignisbaum und Pfadregel

Situation mit bedingter Wahrscheinlichkeit anschaulich darstellen

**Pfadwahrscheinlichkeit:** Wahrscheinlichkeiten entlang des Pfades multiplizieren

**Ereigniswahrscheinlichkeit:** Summe aller Pfadwahrscheinlichkeit die zum Ergebnis führen

z.B. Gefäß mit 2 weißen und 3 schwarzen Kugeln. Solange eine Kugel ziehen und beiseite legen bis mind. 1 weiße und 1 schwarze draussen liegt.



Dazu 2-Mal ziehen:  
 $\hookrightarrow \frac{2}{5} \cdot \frac{3}{4} + \frac{3}{5} \cdot \frac{2}{4} = 0.6$

Dazu 3-Mal ziehen:  
 $\hookrightarrow \frac{2}{5} \cdot \frac{1}{4} \cdot \frac{3}{3} + \frac{3}{5} \cdot \frac{2}{4} \cdot \frac{2}{3} = 0.3$

Dazu 4-Mal ziehen:  
 $\hookrightarrow \frac{3}{5} \cdot \frac{2}{4} \cdot \frac{1}{3} \cdot \frac{2}{2} = 0.1$

## Unabhängigkeit von Ereignissen

A und B sind unabhängig wenn gilt:  $P(A|B) = P(A)$ ,  $P(B|A) = P(B)$  oder  $P(A \cap B) = P(A) \cdot P(B)$

z.B. Gewöhnlicher Würfel wird 1-Mal geworfen

$$\Omega = \{1, 2, 3, 4, 5, 6\}, A = \{2, 4, 6\}, B = \{1, 2, 3\}, C = \{3, 4, 5, 6\}$$

$$A \text{ und } B: P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(\{2\})}{\frac{1}{2}} = \frac{\frac{1}{6}}{\frac{1}{2}} = \frac{1}{3} \neq P(A) = \frac{1}{2} \rightarrow \text{abhängig}$$

$$A \text{ und } C: P(A|C) = \frac{P(A \cap C)}{P(C)} = \frac{P(\{4, 6\})}{\frac{2}{3}} = \frac{\frac{2}{6}}{\frac{2}{3}} = \frac{1}{3} = P(A) = \frac{1}{2} \rightarrow \text{unabhängig}$$

$$\hookrightarrow P(A \cap C) = \frac{1}{2} \cdot \frac{2}{3} = \frac{1}{3}$$

z.B. Vierfeldertafel Mathe und Deutsch Noten Beispiel

$$M \text{ und } D: P(M \cap D) = \frac{16}{24} \neq P(M) \cdot P(D) = \frac{16}{24} \cdot \frac{20}{24} = 0.625 \rightarrow \text{abhängig}$$

## Zufallsvariable

Bildet Scharnier zwischen Statistik und Wahrscheinlichkeitsrechnung

$X$  = Zufallsvariable mit Werten  $x_1, x_2, \dots$  und Wahrscheinlichkeit  $P(X=x_1), P(X=x_2), \dots$

z.B. Gefäß mit 4 von 1-4 nummerierten Kugeln. Nacheinander 2 ziehen ohne zurücklegen


$X$  = Nummer 2. gezogener Kugel

$x$	1	2	3	4
$f_X(x) = P(X=x)$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$


$Z$  = Summe beider gezogenen Kugel

$z$	3	4	5	6	7
$f_Z(z) = P(Z=z)$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{3}$	$\frac{1}{6}$	$\frac{1}{6}$

$f_X(x) = P(x=x)$



$F_X(x) = P(x \leq x)$



## Standardisierte Zufallsvariable

Mit Zufallsvariable  $X$ , Erwartungswert  $E(X)$ , Standardabweichung  $S(X)$

$$W = \frac{X - E(X)}{S(X)} = \frac{1}{S(X)} \cdot X - \frac{E(X)}{S(X)} \quad \text{① } E(W) = 0 \text{ und } S(W) = 1$$

z.B. Vorheriges Beispiel mit Kugeln und Zufallsvariable  $X$

$x$	1	2	3	4
$P(X=x)$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$

$w$	-1.34	-0.45	0.45	1.34
$P(W=w)$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$

$E(W)$	0
$S(W)$	1

## Linearkombination von Zufallsvariablen

$$E(a \cdot X + b \cdot Y + c \cdot Z + \dots) = a \cdot E(X) + b \cdot E(Y) + c \cdot E(Z)$$

$$V(a \cdot X + b \cdot Y + c \cdot Z + \dots) = a^2 \cdot V(X) + b^2 \cdot V(Y) + c^2 \cdot V(Z) \quad \text{② Nur wenn paarweise unabhängig}$$

z.B.  $X, Y, Z$  paarweise unabhängig mit  $E(X)=5, E(Y)=10, E(Z)=15$

und  $V(X)=1, V(Y)=4, V(Z)=2$

$$E(X + \frac{1}{2}Y - 2Z) = E(X) + \frac{1}{2}E(Y) - 2 \cdot E(Z) = 5 + \frac{1}{2} \cdot 10 - 2 \cdot 15 = -20$$

$$V(X + \frac{1}{2}Y - 2Z) = V(X) + (\frac{1}{2})^2 \cdot V(Y) + (-2)^2 \cdot V(Z) = 1 + \frac{1}{4} \cdot 4 + 4 \cdot 2 = 10$$

## Kennzahlen einer Zufallsvariable

Erwartungswert (Mittelwert):  $E(X) = P(X=x_1) \cdot x_1 + P(X=x_2) \cdot x_2 + \dots$

Varianz:  $V(X) = E(X^2) - (E(X))^2$

Standardabweichung:  $S(X) = \sqrt{V(X)}$

z.B. Vorheriges Beispiel mit Kugeln und Zufallsvariable  $X$

$$E(X) = \frac{1}{4} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 3 + \frac{1}{4} \cdot 4 = 2.5$$

$$E(X^2) = \frac{1}{4} \cdot 1^2 + \frac{1}{4} \cdot 2^2 + \frac{1}{4} \cdot 3^2 + \frac{1}{4} \cdot 4^2 = 7.5$$

$$V(X) = 7.5 - 2.5^2 = 1.25$$

$$S(X) = \sqrt{1.25} \approx 1.118$$

## Faires Spiel

Wenn  $E(\text{Auszahlung}) = \text{Einsatz}$

z.B.  $P(2\text{-Mal ziehen}) = \frac{1}{6}, 10\text{- Auszahlung}$

$P(3\text{-Mal ziehen}) = \frac{1}{3}, \text{ Einsatz wird ausgezahlt}$

$P(4\text{-Mal ziehen}) = \frac{1}{2}, 0\text{- Auszahlung}$

Ist Spiel fair mit Einsatz von 4,-?

$$\rightarrow E(\text{Auszahlung}) = \frac{1}{6} \cdot 10 + \frac{1}{3} \cdot 4 + \frac{1}{2} \cdot 0 = 3 \neq 4$$


→ Spiel ist nicht fair

Für welchen Einsatz ist Spiel fair?

$$E(X) = \frac{1}{6} \cdot 10 + \frac{1}{3} \cdot X + \frac{1}{2} \cdot 0 = X$$

$$\frac{5}{3} = \frac{2}{3} \cdot X \rightarrow 2.5 = X$$

## CDF und Wahrscheinlichkeit



$$P(X < 10) = 0.3, P(X \leq 20) = 0.7$$

$$P(X = 10) = 0, P(X = 20) = 0.4$$

$$P(X < 10) = 0.3, P(X < 20) = 0.3$$

$$P(X > 10) = 0.7, P(X > 20) = 0.3$$

$$P(10 < X < 20) = 0.4, P(-10 < X < 20) = 0$$

## 2 Zufallsvariablen

$$E(X + Y) = E(X) + E(Y)$$

$$E(X \cdot Y) = E(X) \cdot E(Y)$$

$$V(X + Y) = V(X) + V(Y)$$

$$V(X \cdot Y) = V(X) \cdot V(Y)$$

③ Nur wenn beide unabhängig

# Wahrscheinlichkeitsverteilungen

## Bernoulli-Verteilung

Bernoulli-Zufallsvariable wenn  $X$  nur Wert 0 oder 1 annimmt

Erfolgswahrscheinlichkeit  $p$  für Wert 1  
Missserfolgwahrscheinlichkeit  $q$  für Wert 0

$$\left. \begin{array}{l} q = 1-p \\ E(X) = p \text{ und } V(X) = p \cdot q \end{array} \right\}$$

z.B. Einmaliger Wurf von gewöhnlichem Würfel

$$X \begin{cases} 1 & \text{wenn Augenzahl gleich 6} \\ 0 & \text{wenn Augenzahl ungleich 6} \end{cases}$$

$$P(X=1) = \frac{1}{6}, P(X=0) = \frac{5}{6}, E(X) = \frac{1}{6}, V(X) = \frac{1}{6} \cdot \frac{5}{6} = \frac{5}{36}$$

## Binomialverteilung

Wenn  $X = X_1 + \dots + X_n$  wobei  $X_1, \dots, X_n$   $n$  voneinander unabhängige Bernoulli-Zufallsvariablen mit gleicher Erfolgswahrscheinlichkeit  $p$  sind

$$X \sim \text{Binom}(n, p)$$

$$P(X=x) = \binom{n}{x} \cdot p^x \cdot q^{n-x} \quad \text{! PMF}$$

$$E(X) = n \cdot p, V(X) = npq \text{ und } S(X) = \sqrt{V(X)}$$

z.B. Multiple-Choice Test mit 9 Fragen. Pro Frage 3 Antwortmöglichkeiten wovon 1 richtig.

Alle Fragen unabhängig beantwortbar. Test bei mind. 6 richtigen Antworten bestanden.

$$X_i \begin{cases} 1 & \text{wenn i-te Frage richtig} \\ 0 & \text{wenn i-te Frage falsch} \end{cases} \quad i = 1, \dots, 9$$

$$X = X_1 + \dots + X_9 = \text{Anzahl Fragen richtig}$$

$$X \sim \text{Binom}(9, \frac{1}{3})$$

$$E(X) = 9 \cdot \frac{1}{3} = 3, V(X) = 9 \cdot \frac{1}{3} \cdot \frac{2}{3} = 2 \text{ und } S(X) = \sqrt{2} \approx 1.4$$

$$P(X=x) = \binom{9}{x} \cdot \left(\frac{1}{3}\right)^x \cdot \left(\frac{2}{3}\right)^{9-x}$$

X	0	1	2	3	4	5	6	7	8	9
P(X=x)	.026	.117	.234	.273	.205	.102	.034	.007	.000	.000

$$\text{Wahrscheinlichkeit für Bestehen: } P(X \geq 6) = P(X=6) + \dots + P(X=9) = 0.041$$

z.B. Würfel mit 1-Mal 1, 2-Mal 2 und 3-Mal 3, 12-Mal werfen

$$\text{Augenzahl 1: } X \sim \text{Binom}(12, \frac{1}{6})$$

$$\rightarrow \text{genau 2-Mal: } P(X=2) = \binom{12}{2} \cdot \left(\frac{1}{6}\right)^2 \cdot \left(\frac{5}{6}\right)^{10} = 0.29$$

$$\rightarrow \text{max. 2-Mal: } P(X \leq 2) = P(X=0) + P(X=1) + P(X=2) \\ \approx 0.1122 + 0.2632 + 0.2361 \approx 0.67$$

$$\text{Augenzahl 2: } X \sim \text{Binom}(12, \frac{1}{3})$$

$$\rightarrow \text{mind. 3 und max. 5: } P(3 \leq X \leq 5) = P(X=3) + P(X=4) + P(X=5) \\ \approx 0.212 + 0.2384 + 0.1808 \approx 0.64$$

$$\text{Augenzahl 3: } X \sim \text{Binom}(12, \frac{1}{2})$$

$$\rightarrow \text{mind. 3-Mal: } P(X \geq 3) = 1 - P(X \leq 2) = 1 - (P(X=0) + P(X=1) + P(X=2)) \\ \approx 1 - (0.0002 + 0.0023 + 0.0161) \approx 0.98$$

z.B. Wie oft muss gewöhnlicher Würfel geworfen werden, damit Wahrscheinlichkeit,

dass immer gerade Augenzahl auftritt 0.5% beträgt

$$\rightarrow X \sim \text{Binom}(n, \frac{1}{2}), P(X=n) = \binom{n}{1} \cdot \left(\frac{1}{2}\right)^n \cdot \left(\frac{1}{2}\right)^{n-n} = 0.005 \rightarrow n = \log_{\frac{1}{2}}(0.005) \approx 7.64 \rightarrow 8\text{-Mal}$$

dass mind. 1-Mal Augenzahl 6 auftritt 99% beträgt

$$\rightarrow X \sim \text{Binom}(n, \frac{1}{6}), P(X \geq 1) = 1 - P(X=0) = 1 - \binom{n}{0} \cdot \left(\frac{1}{6}\right)^0 \cdot \left(\frac{5}{6}\right)^{n-0} = 0.99 \rightarrow n = \log_{\frac{5}{6}}(0.01) \approx 25.26 \rightarrow 26\text{-Mal}$$

## Poisson-Verteilung

Die zuzählenden Ereignisse treten mit einer konstanten mittleren Rate  $\lambda > 0$  ein.

$$X \sim \text{Poisson}(\lambda)$$

$$P(X=x) = e^{-\lambda} \cdot \frac{\lambda^x}{x!} \quad \text{! PMF, } e = \text{Eulersche Zahl}$$

$$E(X) = \lambda, V(X) = \lambda \text{ und } S(X) = \sqrt{V(X)}$$

z.B. Poisson-verteilte Zufallsvariable  $X$  mit Parameter  $\lambda = 4$


$$X \sim \text{Poisson}(4)$$

$$P(X=0) = e^{-4} \cdot \frac{4^0}{0!} \approx 0.015$$

$$P(X=1) = e^{-4} \cdot \frac{4^1}{1!} \approx 0.073$$

$$P(X=2) = e^{-4} \cdot \frac{4^2}{2!} \approx 0.147$$

usw.



$$E(X) = 4, V(X) = 4, S(X) = \sqrt{4} = 2$$

## Approximation von Binomialverteilung durch Poissonverteilung

Binomialverteilte Zufallsvariable  $X \sim \text{Binom}(n, p)$  kann für  $n \gg 50$  und  $p \ll 0.1$  durch Poissonverteilte Zufallsvariable  $Y \sim \text{Poisson}(\lambda)$  mit  $\lambda = n \cdot p$  approximiert werden.

z.B. Auf Flug mit 200 gebuchten Plätzen erscheinen 5% nicht. Wahrscheinlichkeit für genau 8 No-Shows:

$$\text{Exakt: } X \sim \text{Binom}(200, 0.05) \rightarrow P(X=8) = \binom{200}{8} \cdot 0.05^8 \cdot 0.95^{200-8} = 0.1137$$

$$\text{Approximativ: } Y \sim \text{Poisson}(200 \cdot 0.05 (=10)) \rightarrow P(Y=8) = e^{-10} \cdot \frac{10^8}{8!} = 0.1126$$

## Stetige Zufallsvariablen

Wenn  $X$  jede reelle Zahl aus Intervall als Wert annimmt

① Nicht stetige Zufallsvariablen heißen diskret

$$P(X=x) = 0 \text{ für alle } x \text{ Werte}$$

$$P(X \leq x) = P(X < x) / P(X \geq x) = P(X > x)$$

$$P(a \leq X \leq b) = P(a < X < b) = P(a < X \leq b) = P(a \leq X < b) \text{ für alle } a < b$$

$$\text{Erwartungswert } \mu: E(X) = \int_{-\infty}^{\infty} f(x) \cdot x \, dx$$

$$\text{Varianz } \sigma^2: V(X) = E(X^2) - E(X)^2 \text{ mit } \int_{-\infty}^{\infty} f(x) \cdot x^2 \, dx$$

$$\text{Standardabweichung } \sigma: S(X) = \sqrt{V(X)}$$

$$E(X+Y) = E(X) + E(Y), E(\alpha \cdot X) = \alpha \cdot E(X)$$

$$V(\alpha \cdot X + \beta) = \alpha^2 \cdot V(X)$$

$$V(X+Y) = V(X) + V(Y) \text{ für unabhängige } X, Y$$

## Intervallwahrscheinlichkeiten

$$P(X \leq x) = F(x) = \int_{-\infty}^x f(u) \, du \quad \text{① Vorzeichen von } x \text{ übernehmen}$$

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a) = \int_a^b f(u) \, du$$

$$P(X > x) = 1 - P(X \leq x) = 1 - F(x) = \int_x^{\infty} f(u) \, du$$

$$\text{z.B. } F(x) = -0.25x^3 + 0.75x + 0.5$$

$$P(-0.5 < X \leq 0.5) = F(0.5) - F(-0.5) = 0.84375 - 0.15625 = 0.6875$$

$$P(X \geq 0.8) = 1 - F(0.8) = 1 - 0.972 = 0.028$$

## Dichtefunktion PDF $f(x)$


Wenn  $X$  eine stetige Zufallsvariable mit CDF  $F(x)$

$$\text{PDF} \rightarrow F(x) = P(X \leq x) = \int_{-\infty}^x f(u) \, du$$

$f(x)$  ist Ableitung von  $F(x)$ :  $f(x) = F'(x)$

Es gilt immer:  $f(x) > 0$  und  $\int_{-\infty}^{\infty} f(x) \, dx = 1$

z.B. Fläche Dreieck mit Grundlinie 10 und Höhe 0.2



$$P(X \leq 1) = \frac{1}{2} \cdot 1 \cdot 0.1 = 0.05$$

$$P(2 \leq X \leq 4) = 2 \cdot 0.15 + \frac{1}{2} \cdot 2 \cdot 0.05 = 0.35$$

$$P(X=5) = 0$$

$$P(X \geq 7) = \frac{1}{2} \cdot 3 \cdot 0.075 = 0.1125$$

## Kumulative Verteilungsfunktion CDF $F(x)$

Wenn  $X$  eine stetige Zufallsvariable mit Wahrscheinlichkeitsmass  $P$

$$\text{CDF} \rightarrow F(x) = P(X \leq x)$$


## Beispiel

Brenndauer in Jahren	[0,1[	[1,2[	[2,4[	[5,8]
----------------------	-------	-------	-------	-------

Klassenbreite $b_k$	1	1	2	3
---------------------	---	---	---	---

relative Häufigkeit $p_k$	0.4	0.25	0.25	0.1
---------------------------	-----	------	------	-----

relative Häufigkeitsdichte $\frac{p_k}{b_k}$	0.4	0.25	0.125	0.025
--	-----	------	-------	-------



Überprüfungen:

$$f(y) \geq 0 \text{ für alle } y \quad \textcircled{2}$$

$$\int_{-\infty}^{\infty} f(y) \, dy = \int_0^8 \frac{1}{2} \cdot e^{-\frac{y}{2}} \cdot y \, dy = \left[ \frac{1/2}{-1/2} \cdot e^{-\frac{y}{2}} \cdot y \right]_0^\infty = (-e^{-\frac{y}{2}} \cdot \infty) - (-e^{-\frac{y}{2}} \cdot 0) = 1 \quad \textcircled{2}$$

$$P(Y \leq y) = F(y) = \int_{-\infty}^y f(u) \, du$$

$$= \int_0^y \frac{1}{2} \cdot e^{-\frac{u}{2}} \cdot u \, du = \left[ -e^{-\frac{u}{2}} \cdot u \right]_0^y = (-e^{-\frac{y}{2}} \cdot y) - (-e^{-\frac{0}{2}} \cdot 0) = 1 - e^{-\frac{y}{2}}$$

$$F(y) \begin{cases} 0 & \text{für } y < 0 \\ 1 - e^{-\frac{y}{2}} & \text{für } y \geq 0 \end{cases}$$

$$\text{Partielle Integration: } \int_a^b u'(x) \cdot v(x) \, dx = \left[ u(x) \cdot v(x) \right]_a^b - \int_a^b u(x) \cdot v'(x) \, dx$$

$$E(Y) = \int_{-\infty}^{\infty} f(x) \cdot y \, dx = \int_0^8 \frac{1}{2} \cdot e^{-\frac{y}{2}} \cdot y \, dy = \left[ -e^{-\frac{y}{2}} \cdot y \right]_0^\infty - \int_0^8 -e^{-\frac{y}{2}} \cdot 1 \, dy = \left[ -e^{-\frac{y}{2}} \cdot y \right]_0^\infty - \left[ 2 \cdot e^{-\frac{y}{2}} \right]_0^\infty = -\left( -e^{-\frac{y}{2}} \cdot \infty \right) - \left( -e^{-\frac{y}{2}} \cdot 0 \right) - \left( 2 \cdot e^{-\frac{y}{2}} \cdot \infty \right) - \left( 2 \cdot e^{-\frac{y}{2}} \cdot 0 \right) = \underline{\underline{2}}$$

$$V(Y) = E(Y^2) - E(Y)^2 = \int_0^8 \frac{1}{2} \cdot e^{-\frac{y}{2}} \cdot y^2 \, dy - 2^2 = \dots = \underline{\underline{4}}$$

$$S(Y) = \sqrt{V(Y)} = \sqrt{4} = \underline{\underline{2}}$$

## Integrieren / Ableiten

$x^n$	$\frac{1}{n+1} \cdot x^{n+1}$	$n \cdot x^{n-1}$	Ableiten
$e^x$	$e^x$	$e^x$	$F(x) \rightarrow f(x)$
$e^{-x}$	$-e^{-x}$	$-e^{-x}$	$f(x) \rightarrow f'(x)$
$e^{2x}$	$2 \cdot e^{2x}$	$2 \cdot e^{2x}$	
$e^{x^2}$	$2x \cdot e^{x^2}$	$2x \cdot e^{x^2}$	

## Normalverteilung / Gauss-Verteilung

Wenn stetige Zufallsvariable  $X$  mit  $\mu$  und  $\sigma$  folgende PDF besitzt:

$$f(x) = \frac{1}{\sqrt{2 \cdot \pi} \cdot \sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Schreibweise:  $X \sim \text{Normal}(\mu, \sigma)$  oder kurz  $X \sim N(\mu, \sigma)$

$$E(X) = \mu, V(X) = \sigma^2, S(X) = \sigma$$

$$P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 0.68$$


$$P(\mu - 2 \cdot \sigma \leq X \leq \mu + 2 \cdot \sigma) \approx 0.95$$

$$P(\mu - 3 \cdot \sigma \leq X \leq \mu + 3 \cdot \sigma) \approx 0.997$$

z.B. 10 Körpergrößen mit  $\mu = 178$  und  $\sigma = 10$

$$X \sim N(178, 10) \text{ mit}$$


$$f(x) = \frac{1}{\sqrt{2 \cdot \pi} \cdot 10} \cdot e^{-\frac{(x-178)^2}{200}}$$



## CDF Normalverteilung

$$\text{CDF} \rightarrow \Phi(u) = \frac{1}{\sqrt{2 \cdot \pi}} \int_{-\infty}^u e^{-\frac{(x-\mu)^2}{2\sigma^2}} \, dx$$

① Werte von  $\Phi(u)$  aus Tabelle entnehmen



## Linearkombination Normalverteilung

Wenn  $X \sim N(\mu_X, \sigma_X^2)$ ,  $Y \sim N(\mu_Y, \sigma_Y^2)$ ,  $\alpha$  und  $\beta$  Zahlen (nicht beide 0)

Dann gilt für Zufallsvariable  $Z = \alpha \cdot X + \beta \cdot Y$ .

$Z$  ist immer auch normalverteilt, also  $Z \sim N(\mu_Z, \sigma_Z^2)$

$$\mu_Z = \alpha \cdot \mu_X + \beta \cdot \mu_Y, \sigma_Z^2 = \sqrt{\alpha^2 \cdot \sigma_X^2 + \beta^2 \cdot \sigma_Y^2} \quad (\sigma_Z \text{ nur wenn } X \text{ und } Y \text{ unabhängig})$$

z.B. unabhängig:  $X \sim N(0, 1)$ ,  $Y \sim N(1, 2)$  und  $\alpha = 3$ ,  $\beta = 2$

$$Z = 3 \cdot X + 2 \cdot Y \sim N(3 \cdot 0 + 2 \cdot 1, \sqrt{3^2 \cdot 1^2 + 2^2 \cdot 2^2}) \sim N(2, 5)$$

## Standardnormalverteilung

Wenn  $X$  normalverteilte Zufallsvariable mit  $\mu=0$  und  $\sigma=1$ , also  $X \sim N(0, 1)$

$$\text{Dann lautet PDF von } X: \varphi(x) = \frac{1}{\sqrt{2 \cdot \pi}} \cdot e^{-\frac{x^2}{2}}$$

## Standardnormalverteilungstabelle

U muss standardnormalverteilte Zufallsvariable sein,  $U \sim N(0,1)$

$$\text{Ansonsten } X \sim N(\mu, \sigma) \rightarrow U = \frac{X - \mu}{\sigma} \sim N(0,1)$$

$$P(U < u) = \Phi(u) / P(U < -u) = 1 - \Phi(u) \quad \text{① Vorzeichen von } u \text{ nicht übernehmen}$$

$$P(U > u) = 1 - \Phi(u) / P(U > -u) = \Phi(u)$$

$$P(-u < U < u) = 2 \cdot \Phi(u) - 1 / P(-a < U < b) = \Phi(b) + \Phi(a) - 1 / P(a < U < b) = \Phi(b) - \Phi(a)$$

$$\Phi(-u) = 1 - \Phi(u)$$

z.B.  $P(U < -1)$  mit  $U \sim N(0,1)$

$$= 1 - \Phi(1) = 1 - 0.8413 = \underline{\underline{0.1587}}$$

$$P(X < 5) \text{ mit } X \sim N(3,1)$$

$$X \text{ nicht standardnormalverteilt} \rightarrow U = \frac{X - 3}{1} = X - 3$$

$$= P(X < 5 - 3) = P(U < 2) = \Phi(2) = \underline{\underline{0.9772}}$$

$$P(-0.5 < U < 0.5) \text{ mit } U \sim N(0,1)$$

$$= 2 \cdot \Phi(0.5) - 1 = 2 \cdot 0.6915 - 1 = \underline{\underline{0.383}}$$

## Stetigkeitskorrektur

Wenn diskrete Verteilung durch Normalverteilung approximiert wird

① Nicht nötig bei Intervall oder Durchschnitt ( $\bar{Z}_n$ )

$$P(Z < b) \approx P(Z < b+0.5)$$

$$P(Z > a) \approx P(Z > a-0.5)$$

$$P(a < Z < b) \approx P(a-0.5 < Z < b+0.5)$$

$< \neq <$  und  $> \neq >$  bei diskretem  $Z$

z.B.  $P(X < 5.8)$  zu  $P(X < 5.7+0.5)$

$P(X > 5.8)$  zu  $P(X > 5.9-0.5)$

## Approximation Binomialverteilung durch Normalverteilung

Wenn Zufallsvariablen  $X$  binomialverteilt mit  $n$  und  $p$ , also  $X \sim B(n,p)$

Dann gilt für normalverteilte Zufallsvariable  $Z \sim N(n \cdot \mu, \sqrt{n} \cdot \sigma)$ :

z.B.  $n$ -Mal Würfel mit Augenzahlen 1,2,3 (auf 2 Seiten) werfen

$$\text{wobei } Z_i = \begin{cases} 1 & \text{wenn Augenzahl 3} \\ 0 & \text{sonst} \end{cases}, Z_1, \dots, Z_n \text{ Bernoulli-verteilt mit } p = 1/3$$

$$\mu = p = 1/3, \sigma = \sqrt{p \cdot (1-p)} = \sqrt{2}/3$$

Approximative Berechnung von  $P(Z_{24} < 10)$

$$Z_{24} = X_1 + \dots + X_{24}: E(Z_{24}) = n \cdot \mu = 24 \cdot 1/3 = 8, S(Z_{24}) = \sqrt{n} \cdot \sigma = \sqrt{24} \cdot \sqrt{2}/3 \approx 2.308$$

$$Z_{24} \sim N(8, 2.308) \text{ nicht standardnormalverteilt} \rightarrow U = \frac{Z_{24} - 8}{2.308}$$

$$= P(Z_{24} < 10 + 0.5) = P(Z_{24} < \frac{10.5 - 8}{2.308}) = P(Z_{24} < 1.08) = \Phi(1.08) = \underline{\underline{0.8539}}$$

Zentraler Grenzwertsatz Mittelwert und Standardabweichung sind für grosse  $n$  näherungsweise normalverteilt unabhängig der ursprünglichen Verteilung

Wenn Zufallsvariablen  $X_1, \dots, X_n$  identisch verteilt und paarweise unabhängig mit  $\mu = E(X_1) = \dots = E(X_n)$  und  $\sigma = S(X_1) = \dots = S(X_n)$

Dann gilt für Zufallsvariable  $\bar{Z}_n = X_1 + \dots + X_n$ :

$$E(\bar{Z}_n) = n \cdot \mu, S(\bar{Z}_n) = \sqrt{n} \cdot \sigma, V(\bar{Z}_n) = n \cdot \sigma^2$$

$$\bar{Z}_n \sim N(n \cdot \mu, \sqrt{n} \cdot \sigma)$$

Dann gilt für Zufallsvariable  $\bar{Z}_n = \frac{X_1 + \dots + X_n}{n}$

$$E(\bar{Z}_n) = \mu, S(\bar{Z}_n) = \frac{\sigma}{\sqrt{n}}, V(\bar{Z}_n) = \frac{\sigma^2}{n}$$

$$\bar{Z}_n \sim N(\mu, \frac{\sigma}{\sqrt{n}})$$

z.B.  $n$ -Mal zufällige reelle Zahl aus Intervall  $[-1, 1]$  wählen

wobei  $Z_i = i$ -te gewählte Zahl,  $Z_1, \dots, Z_n$  stetig gleichverteilt

$$\mu = \frac{-1+1}{2} = 0, \sigma = \sqrt{\frac{(1-(-1))^2}{12}} = \frac{1}{\sqrt{3}}$$

Approximative Berechnung von  $P(-0.1 < \bar{Z}_{48} < 0.1)$

$$\bar{Z}_{48} = \frac{X_1 + \dots + X_{48}}{48}: E(\bar{Z}_{48}) = \mu = 0, S(\bar{Z}_{48}) = \frac{\sigma}{\sqrt{n}} = \frac{1/\sqrt{3}}{\sqrt{48}} = \frac{1}{\sqrt{144}}$$

$$\bar{Z}_{48} \sim N(0, \frac{1}{\sqrt{144}}) \text{ nicht standardnormalverteilt} \rightarrow U = \frac{\bar{Z}_{48} - 0}{1/\sqrt{144}} = \frac{\bar{Z}_{48}}{1/\sqrt{144}}$$

$$= P\left(\frac{-0.1}{1/\sqrt{144}} < \bar{Z}_{48} < \frac{0.1}{1/\sqrt{144}}\right) = P(-1.2 < \bar{Z}_{48} < 1.2) = 2 \cdot \Phi(1.2) - 1 = 2 \cdot 0.8849 - 1 = \underline{\underline{0.7698}}$$

Berechnung von  $n$ , so dass  $P(-0.1 < \bar{Z}_n < 0.1) = 0.9$

$$E(\bar{Z}_n) = \mu = 0, S(\bar{Z}_n) = \frac{\sigma}{\sqrt{n}} = \frac{1/\sqrt{3}}{\sqrt{n}} = \frac{1}{\sqrt{3n}}$$

$$\bar{Z}_n \sim N(0, 1/\sqrt{3n}) \text{ nicht standardnormalverteilt} \rightarrow U = \frac{\bar{Z}_n - 0}{1/\sqrt{3n}} = \frac{\bar{Z}_n}{1/\sqrt{3n}}$$


$$P(-0.1 < \bar{Z}_n < 0.1) = 0.9 \rightarrow 2 \cdot \Phi(0.1) - 1 = 0.9 \rightarrow \Phi(0.1) = 0.95$$

$$\text{Tabelle: } u = \frac{1.64 + 1.65}{2} = 1.645 \rightarrow \frac{0.1}{1/\sqrt{3n}} = 1.645 \rightarrow n = \frac{(1.645 \cdot 1)^2}{3} \approx \underline{\underline{90}}$$

## Gleichverteilung

Wenn stetige Zufallsvariable  $X$  folgende PDF besitzt mit  $a < b$ :

$$f(x) \begin{cases} \frac{1}{b-a} & \text{für } a < x < b \\ 0 & \text{für } x \leq a \text{ und } x \geq b \end{cases}$$



Schreibweise:  $X \sim \text{Uniform}(a, b)$

(gleichverteilt auf  $[a, b]$ )

$$E(X) = \frac{a+b}{2}, V(X) = \frac{(b-a)^2}{12}$$

z.B.  $X \sim \text{Uniform}(0, 2\pi)$

$$E(X) = \frac{0+2\pi}{2} = \pi$$

$$V(X) = \frac{(2\pi-0)^2}{12} = \frac{\pi^2}{3}$$

z.B. Berechnung von  $\mu$ , so dass  $P(Z < 500) = 0.02$  ① 0.02 nicht in Tabelle, daher  $P(Z = -u)$

$$E(Z) = \mu, S(Z) = 1,$$

$$Z \sim N(\mu, 1) \text{ nicht standardnormalverteilt} \rightarrow U = \frac{Z - \mu}{1} = Z - \mu$$

$$P(Z < 500) = 0.002 \rightarrow P(U < -u) = 1 - \Phi(u) = 0.002 \rightarrow \Phi(u) = 0.998$$

$$\text{Tabelle: } u = 2.88 \rightarrow 500 - \mu = 2.88 \rightarrow \mu = \underline{\underline{502.88}}$$

z.B. Berechnung von  $\sigma$ , so dass  $P(-3 < Z < 3) = 0.99$

$$E(Z) = \mu, S(Z) = \sigma$$

$$Z \sim N(\mu, \sigma^2) \text{ nicht standardnormalverteilt} \rightarrow U = \frac{Z - \mu}{\sigma} = \frac{Z}{\sigma}$$

$$P(-3 < Z < 3) = 0.99 \rightarrow 2 \cdot \Phi(u) - 1 = 0.99 \rightarrow \Phi(u) = 0.995$$

$$\text{Tabelle: } u = \frac{2.57 + 2.58}{2} = 2.575 \rightarrow \frac{3}{\sigma} = 2.575 \rightarrow \sigma = \underline{\underline{1.165}}$$


# Regression

## Lineare Regression

Gegeben: Datenpaare  $(x_1, y_1), \dots, (x_n, y_n)$  mit linearen Zusammenhang

Gesucht: Gerade  $y = a \cdot x + b$ , welche Datenpaare möglichst gut approximiert

Bestmögliche Gerade heisst Regressionsgerade



## Régressionsgerade

Verwendung: Prognose/Erklärung von Merkmal Y durch Merkmal X

Gegeben: Datenpaare mit Mittelwerte  $\bar{x}, \bar{y}$ , Varianzen  $\tilde{v}_x, \tilde{v}_y$ , Kovarianz  $\tilde{v}_{xy}$

Dann gilt für Regressionsgerade  $y = a \cdot x + b$ :

$$\text{Steigung } a = \frac{\tilde{v}_{xy}}{\tilde{v}_x}, \text{ y-Achsenabschnitt } b = \bar{y} - a \cdot \bar{x}$$

$$\text{Summe der Quadrate der Residuen: } \epsilon_1^2 + \dots + \epsilon_n^2 = n \cdot \left( \bar{v}_y - \frac{\tilde{v}_{xy}^2}{\tilde{v}_x} \right)$$

i	1	2	3	4	Summe	Mittelwert
$x_i$	4	5	5	6	20	$\bar{x}$
$y_i$	2	3	6	5	16	$\bar{y}$
$x_i^2$	16	25	25	36	102	$\tilde{v}_x = 25.5 - \bar{x}^2 = 0.5$
$y_i^2$	4	9	36	25	74	$\tilde{v}_y = 18.5 - \bar{y}^2 = 2.5$
$x_i \cdot y_i$	8	15	30	30	83	$\tilde{v}_{xy} = 20.75 - (\bar{x} \cdot \bar{y}) = 0.75$

$$\text{Standardabweichungen: } \tilde{s}_x = \sqrt{0.5} \approx 0.71, \quad \tilde{s}_y = \sqrt{2.5} \approx 1.58$$

$$\text{Korrelationskoeffizient nach Pearson: } r_{xy} = \frac{\tilde{v}_{xy}}{\tilde{s}_x \cdot \tilde{s}_y} = \frac{0.75}{0.71 \cdot 1.58} \approx 0.67$$


①  $0.5 < r_{xy} < 0.75 \rightarrow x$  und  $y$  moderat positiv korreliert

Régressionsgerade  $y = a \cdot x + b$  mit:

$$a = \frac{\tilde{v}_{xy}}{\tilde{v}_x} = \frac{0.75}{0.5} = 1.5$$

$$b = \bar{y} - a \cdot \bar{x} = 4 - 1.5 \cdot 5 = -3.5$$

$$\epsilon_1^2 + \dots + \epsilon_n^2 = n \cdot \left( \bar{v}_y - \frac{\tilde{v}_{xy}^2}{\tilde{v}_x} \right) = 4 \cdot \left( 2.5 - \frac{0.75^2}{0.5} \right) = 5.5$$



## Methode der kleinsten Quadrate

Gegeben: Datenpaare und eine Gerade  $y = a \cdot x + b$

Dann heißen für  $i = 1, 2, \dots, n$ :

$y_i$ : beobachtete/totale y-Werte

$\hat{y}_i = a \cdot x_i + b$ : prognostizierte/erklärte y-Werte


$\epsilon_i = y_i - \hat{y}_i$ : Residuen

Gerade, bei der Summe der Quadrate aller Residuen

$\epsilon_1 + \epsilon_2 + \dots + \epsilon_n$  am kleinsten ist, heisst Regressionsgerade

z.B. Residuen bei Gerade  $y = x - 1$

i	$x_i$	$y_i$	$\hat{y}_i = x_i - 1$	$\epsilon_i = y_i - \hat{y}_i$	$\epsilon_i^2$
1	4	2	3	-1	1
2	5	3	4	-1	1
3	5	6	4	2	4
4	6	5	5	0	0
				Summe	6



## Varianzzerlegung

Gegeben: Regressionsgerade zu Datenpaare mit Mittelwerten  $\bar{x}, \bar{y}$ , Varianzen  $\tilde{v}_x, \tilde{v}_y$ , Kovarianz  $\tilde{v}_{xy}$

Varianzen  $\tilde{v}_x, \tilde{v}_y$ , Kovarianz  $\tilde{v}_{xy}$ ,  $\hat{y}_i = a \cdot x_i + b$  mit Mittelwert  $\bar{y}$  und Varianz  $\tilde{v}_{\hat{y}}$

Dann gilt: Mittelwerte  $\bar{y} = \bar{x}$  und  $\bar{\epsilon} = 0$

$$\text{Varianzen } \tilde{v}_y = \tilde{v}_{\hat{y}} + \tilde{v}_{\epsilon} \text{ und } \tilde{v}_{\hat{y}} = \frac{\tilde{v}_{xy}^2}{\tilde{v}_x}$$

## Bestimmtheitsmaß $R^2$

Verhältnis erklärt Varianz  $\tilde{v}_{\hat{y}}$  zu totaler Varianz  $\tilde{v}_y$

$$R^2 = \frac{\tilde{v}_{\hat{y}}}{\tilde{v}_y} = r_{xy}^2, \quad 0 \leq R^2 \leq 1$$


① Wenn alle Datenpaare auf Regressionsgerade z.B.  $0.5 \rightarrow 50\%$

" $R^2$  der Gesamtvarianz in den y-Daten kann durch Regressionsgerade erklärt werden."

## Nichtlineare Regression

Gegeben: Datenpaare  $(x_1, y_1), \dots, (x_n, y_n)$  mit nicht linearen Zusammenhang

Gesucht: Kurve  $y = f(x)$ , welche im Sinne der Methode der kleinsten Quadrate die Datenpaare möglichst gut annähert



① Mit Variablentransformation auf lineare Regression zurückführen

	0	2	4	8
$x_i$	0	0.75	0.35	0.15
$y_i$	1	0.75	0.35	0.15

$t_i$	0	2	4	8
$z_i = \log_{10}(y_i)$	0	-0.12	-0.46	-0.82

$$\text{Mittelwert: } \bar{t} = 3.5, \bar{z} = -0.35$$

$$\text{Varianz: } \tilde{v}_z = 8.75, \tilde{v}_{\epsilon} = 0.1021$$

$$\text{Kovarianz: } \tilde{v}_{tz} = -0.935$$

## Variablentransformation

Exponentialfunktion:  $y = a \cdot b^x$

$$\stackrel{z}{\underline{y}} = c + t + \delta \quad \rightarrow \log_{10}(y) = \log_{10}(b) \cdot x + \log_{10}(a)$$

Potenzfunktion:  $y = a \cdot x^m$

$$\stackrel{z}{\underline{y}} = c + t + \delta \quad \rightarrow \log_{10}(y) = m \cdot \log_{10}(x) + \log_{10}(a)$$

Quadratischefunktion:  $y = a \cdot x^2 + b$

$$\stackrel{z}{\underline{y}} = c + t + \delta \quad \rightarrow y = a \cdot x^2 + b \quad (\text{mit } x \geq 0)$$

Kehrwertfunktion:  $y = \frac{1}{a \cdot x + b}$

$$\stackrel{z}{\underline{y}} = c + t + \delta \quad \rightarrow \frac{1}{y} = a \cdot x + b$$

Régressionsgerade  $z = c \cdot t + \delta$  mit:

$$c = \frac{\tilde{v}_{tz}}{\tilde{v}_t} = \frac{-0.935}{8.75} = -0.107$$

$$\delta = \bar{z} - c \cdot \bar{t} = -0.35 - (-0.107) \cdot 3.5 = 0.0245$$

$$\text{Also: } z = -0.107 \cdot t + 0.0245$$

Régressionskurve  $y = a \cdot b^x$  mit:

$$a = 10^\delta = 10^{0.0245} \approx 1.06$$

$$b = 10^c = 10^{-0.107} \approx 0.78$$

$$\text{Also: } y \approx 1.06 \cdot 0.78^x$$

# Schliessende Statistik

## Intervallschätzung

Schätzintervall  $[\Theta_u, \Theta_o]$  bilden, welches  $\mu, \sigma^2, p$  mit vorgegebener Sicherheit  $\gamma$  enthält.

Begriffe: Schätzintervall = Vertrauensintervall = Konfidenzintervall

Sicherheit = Vertrauenniveau = Konfidenzlevel

① Je höher das Konfidenzlevel, desto breiter das Konfidenzintervall.

↪ Wollen mehr Sicherheit, dass Intervall wahren Wert enthält → breiteres Intervall

Je grösser der Stichprobenumfang, desto enger das Konfidenzintervall.

↪ Grösserer Stichprobenumfang gibt mehr Informationen und reduziert Unsicherheit → engerer Intervall

(1) Verteilung der Grundgesamtheit	(2) Param.	(3) Schätzfunktionen	(4) zugehörige standardisierte Zufallsvariable	(5) Verteilung und benötigte Quantile	(6) Zufallsvariablen für Intervallgrenzen
1 Normalverteilung ( $\text{Varianz } \sigma^2$ bekannt)	$\mu$	$\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$	$U = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$	Standardnormalverteilung (Tabelle 2) $c = u_p$ mit $p = \frac{1+\gamma}{2}$	$\Theta_u = \bar{X} - c \cdot \frac{\sigma}{\sqrt{n}}$ $\Theta_o = \bar{X} + c \cdot \frac{\sigma}{\sqrt{n}}$
2 Normalverteilung ( $\text{Varianz } \sigma^2$ unbekannt und $n \leq 30$ ; sonst Fall 1 mit $s$ als Schätzwert für $\sigma$ )	$\mu$	$\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$ $S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^n (X_i - \bar{X})^2$	$T = \frac{\bar{X} - \mu}{S / \sqrt{n}}$	$t$ -Verteilung (Tabelle 4) mit $f = n - 1$ $c = t_{(p; f)}$ mit $p = \frac{1+\gamma}{2}$	$\Theta_u = \bar{X} - c \cdot \frac{S}{\sqrt{n}}$ $\Theta_o = \bar{X} + c \cdot \frac{S}{\sqrt{n}}$
3 Normalverteilung	$\sigma^2$	$\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$ $S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^n (X_i - \bar{X})^2$	$Z = (n-1) \frac{S^2}{\sigma^2}$	Chi-Quadrat-Verteilung (Tabelle 3) mit $f = n - 1$ $c_1 = z_{(p_1; f)}$ mit $p_1 = \frac{1-\gamma}{2}$ $c_2 = z_{(p_2; f)}$ mit $p_2 = \frac{1+\gamma}{2}$	$\Theta_u = \frac{(n-1) \cdot S^2}{c_2}$ $\Theta_o = \frac{(n-1) \cdot S^2}{c_1}$
4 Bernoulli-Verteilung Anteilsschätzung (mit $n\hat{p}(1-\hat{p}) > 9$ )	$p$	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ $X_i$ 0/1-wertig mit $P(X_i = 1) = p$	$U = \frac{\bar{X} - p}{\sqrt{p(1-p)/n}}$	Standardnormalverteilung (näherungsweise), Tabelle 2 $c = u_q$ mit $q = \frac{1+\gamma}{2}$	$\Theta_u = \bar{X} - c \cdot \sqrt{\frac{\bar{X} \cdot (1-\bar{X})}{n}}$ $\Theta_o = \bar{X} + c \cdot \sqrt{\frac{\bar{X} \cdot (1-\bar{X})}{n}}$
5 beliebig mit $n > 30$	$\mu, \sigma^2$			wie im Fall 1 (gegebenenfalls mit $s$ als Schätzwert für $\sigma$ ) bzw. im Fall 3	

z.B. Gegeben: 27 defekte Teile in Stichprobe von Umfang  $n = 500$

Gesucht: Schätzintervall für  $p$  mit Vertrauenniveau von 95%

$p$  gesucht → Fall 4

$$1. \hat{p} = \bar{x} = \frac{27}{500} = 0.054 \rightarrow \text{Faustregel prüfen: } 500 \cdot 0.054(1-0.054) = 25.542 > 9 \quad \checkmark$$

$$2. p = \frac{1+0.95}{2} = 0.975, c = u_{0.975} = 1.96 \text{ (Tabelle 2)}$$

$$3. \Theta_u = 0.054 - 1.96 \cdot \sqrt{\frac{0.054 \cdot (1-0.054)}{500}} = 0.034 \quad \left. \begin{array}{l} \\ \end{array} \right\} p : [0.034, 0.074]$$

$$\Theta_o = 0.054 + 1.96 \cdot \sqrt{\frac{0.054 \cdot (1-0.054)}{500}} = 0.074$$

Ziel: Von bekannter Stichprobe Rückschlüsse auf unbekannte Grundgesamtheit ziehen

z.B. Von bekanntem Stichprobenmittelwert  $\bar{x}$  auf unbekannten Grundgesamtheitmittelwert  $\mu$  schliessen

## Punktschätzung

Mittelwert  $\bar{x} = \frac{x_1 + \dots + x_n}{n}$  der Stichprobe ist geeigneter Mittelwert  $\mu$  der Grundgesamtheit.

Korrigierte Standardabweichung  $s = \sqrt{\frac{x_1^2 + \dots + x_n^2}{n} - \bar{x}^2}$  der Stichprobe ist geeignete Standardabweichung  $\sigma$  der Grundgesamtheit.

z.B. Gegeben:  $X$  normalverteilt,  $n = 10, \bar{x} = 102, s^2 = 16$

Gesucht: Schätzintervall für  $\mu$  und  $\sigma^2$  mit Vertrauenniveau von 99%

$n < 30 \rightarrow \mu$  gesucht →  $\sigma^2$  unbekannt → Fall 2

$$1. f = 10 - 1 = 9, p = \frac{1+0.99}{2} = 0.995, c = u_{0.995}, s = 3.25 \text{ (Tabelle 4)}$$

$$2. \Theta_u = 102 - 3.25 \cdot \frac{\sqrt{16}}{\sqrt{10}} = 97.89 \quad \left. \begin{array}{l} \\ \end{array} \right\} \mu : [97.89, 106.11]$$

$$\Theta_o = 102 + 3.25 \cdot \frac{\sqrt{16}}{\sqrt{10}} = 106.11$$

$n < 30 \rightarrow \sigma^2$  gesucht → Fall 3

$$1. f = 10 - 1 = 9$$

$$p_1 = \frac{1-0.99}{2} = 0.005, c_1 = u_{0.005}, s = 1.73 \text{ (Tabelle 3)}$$

$$p_2 = \frac{1+0.99}{2} = 0.995, c_2 = u_{0.995}, s = 23.59 \text{ (Tabelle 3)}$$

$$2. \Theta_u = \frac{(10-1) \cdot 16}{23.59} = 6.1 \quad \left. \begin{array}{l} \\ \end{array} \right\} \sigma^2 : [6.1, 83.24]$$

$$\Theta_o = \frac{(10-1) \cdot 16}{1.73} = 83.24$$

z.B. Gegeben:  $X$  normalverteilt,  $n = 100, \bar{x} = 0.62, s = 0.35$

Gesucht: Schätzintervall für  $\mu$  mit Irrtumswahrscheinlichkeit von 5%


$n > 30 \rightarrow$  Fall 5 →  $\mu$  gesucht → Fall 1 mit  $s$  als Schätzwert für  $\sigma$

$$1. \gamma = 1-0.05 = 0.95, p = \frac{1+0.95}{2} = 0.975, c = u_{0.975} = 1.96 \text{ (Tabelle 2)}$$

$$2. \Theta_u = 0.62 - 1.96 \cdot \frac{0.35}{\sqrt{100}} = 0.613 \quad \left. \begin{array}{l} \\ \end{array} \right\} \mu : [0.613, 0.627]$$

$$\Theta_o = 0.62 + 1.96 \cdot \frac{0.35}{\sqrt{100}} = 0.627$$

**Tabelle 1: CDF  $\Phi(u)$  der Standardnormalverteilung**



$$P(U \leq u) = \Phi(u)$$


$$P(U \geq u) = 1 - \Phi(u)$$

$$P(-u \leq U \leq u) = 2 \cdot \Phi(u) - 1$$

$$\Phi(-u) = 1 - \Phi(u)$$

$u$	0	1	2	3	4	5	6	7	8	9
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998
3.5	0.9998	0.9998	0.9998	0.9998	0.9998	0.9998	0.9998	0.9998	0.9998	0.9998
3.6	0.9998	0.9998	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999
3.7	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999
3.8	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999
3.9	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000

**Tabelle 2: Quantile der Standardnormalverteilung**




$p$ : vorgegebene Wahrscheinlichkeit

$u_p$ : zur Wahrscheinlichkeit  $p$  gehöriges Quantil

$p$	$u_p$	$p$	$u_p$
0.90	1.282	0.10	-1.282
0.95	1.645	0.05	-1.645
0.975	1.960	0.025	-1.960
0.99	2.326	0.01	-2.326
0.995	2.576	0.005	-2.576
0.999	3.090	0.001	-3.090


**Tabelle 3: Quantile der Chi-Quadrat-Verteilung**



$p$  : vorgegebene Wahrscheinlichkeit  
 $z_{(p;f)}$  : zur Wahrscheinlichkeit  $p$  gehöriges Quantil bei  $f$  Freiheitsgraden

$f$	$p$									
	0.005	0.01	0.025	0.05	0.1	0.9	0.95	0.975	0.99	0.995
1	0.000	0.000	0.001	0.004	0.016	2.71	3.84	5.02	6.63	7.88
2	0.010	0.020	0.051	0.103	0.211	4.61	5.99	7.38	9.21	10.60
3	0.072	0.115	0.216	0.352	0.584	6.25	7.81	9.35	11.34	12.84
4	0.207	0.297	0.484	0.711	1.064	7.78	9.49	11.14	13.28	14.86
5	0.41	0.55	0.83	1.15	1.61	9.24	11.07	12.83	15.09	16.75
6	0.68	0.87	1.24	1.64	2.20	10.64	12.59	14.45	16.81	18.55
7	0.99	1.24	1.69	2.17	2.83	12.02	14.07	16.01	18.48	20.28
8	1.34	1.65	2.18	2.73	3.49	13.36	15.51	17.53	20.09	21.95
9	1.73	2.09	2.70	3.33	4.17	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	17.28	19.68	21.92	24.72	26.76
12	3.07	3.57	4.40	5.23	6.30	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	21.06	23.68	26.12	29.14	31.32
15	4.60	5.23	6.26	7.26	8.55	22.31	25.00	27.49	30.58	32.80
16	5.14	5.81	6.91	7.96	9.31	23.54	26.30	28.85	32.00	34.27
17	5.70	6.41	7.56	8.67	10.09	24.77	27.59	30.19	33.41	35.72
18	6.26	7.01	8.23	9.39	10.86	25.99	28.87	31.53	34.81	37.16
19	6.84	7.63	8.91	10.12	11.65	27.20	30.14	32.85	36.19	38.58
20	7.43	8.26	9.59	10.85	12.44	28.41	31.41	34.17	37.57	40.00
22	8.6	9.5	11.0	12.3	14.0	30.8	33.9	36.8	40.3	42.8
24	9.9	10.9	12.4	13.8	15.7	33.2	36.4	39.4	43.0	45.6
26	11.2	12.2	13.8	15.4	17.3	35.6	38.9	41.9	45.6	48.3
28	12.5	13.6	15.3	16.9	18.9	37.9	41.3	44.5	48.3	51.0
30	13.8	15.0	16.8	18.5	20.6	40.3	43.8	47.0	50.9	53.7
40	20.7	22.2	24.4	26.5	29.1	51.8	55.8	59.3	63.7	66.8
50	28.0	29.7	32.4	34.8	37.7	63.2	67.5	71.4	76.2	79.5
60	35.5	37.5	40.5	43.2	46.5	74.4	79.1	83.3	88.4	92.0
70	43.3	45.4	48.8	51.7	55.3	85.5	90.5	95.0	100.4	104.2
80	51.2	53.5	57.2	60.4	64.3	96.6	101.9	106.6	112.3	116.3
90	59.2	61.8	65.6	69.1	73.3	107.6	113.1	118.1	124.1	128.3
100	67.3	70.1	74.2	77.9	82.4	118.5	124.3	129.6	135.8	140.2

**Tabelle 4: Quantile der t-Verteilung von «Student»**



$p$  : vorgegebene Wahrscheinlichkeit  
 $t_{(p;f)}$  : zur Wahrscheinlichkeit  $p$  gehöriges Quantil bei  $f$  Freiheitsgraden

$f$	$p$				
	0.9	0.95	0.975	0.99	0.995
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
22	1.321	1.717	2.074	2.508	2.819
24	1.318	1.711	2.064	2.492	2.797
26	1.315	1.706	2.056	2.479	2.779
28	1.313	1.701	2.048	2.467	2.763
30	1.310	1.697	2.042	2.457	2.750
40	1.303	1.684	2.021	2.423	2.704
50	1.299	1.676	2.009	2.403	2.678
60	1.296	1.671	2.000	2.390	2.660
100	1.290	1.660	1.984	2.364	2.626
200	1.286	1.653	1.972	2.345	2.601
500	1.283	1.648	1.965	2.334	2.586
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\infty$	1.282	1.645	1.960	2.326	2.576

$$t_{(1-p;f)} = -t_{(p;f)}$$